

LOG BOOK PEMBIMBINGAN PRA PROPOSAL

Nama Mahasiswa : Handi Dwi Cahyo
 Nim : L0122072
 Calon Tema Proposal : *Deteksi Cacat PCB dengan Penjebaran yang Failikal melalui Arsitektur Neuro-Symbolic*
 Calon Pembimbing 1 : *Fadher R-CHN dan Spase Obique Decision Tree*
 : Esti Suryani, S.Si, M.Kom.

Progres yang direncanakan		Progres yang dicapai		Hambatan	Tanda Tangan
Tanggal	Rencana	Tanggal	Hasil capaian		
04/02/26	Diskusi tentang domain dan metode yang akan digunakan	04/02/26	Domain disepakati pada bidang Image Processing dan metode XAI		
13/03/26	Menyampaikan latar belakang penelitian	13/03/26	Urgensi belum terlihat di latar belakang		
20/03/26	Menyampaikan Urgensi beserta Novelty pada Latar Belakang	20/03/26	Urgensi dan Novelty sudah terlihat tetapi perlu perbaikan pada penulisan		
10/04/26	Menyampaikan BAB kedua	10/04/26	BAB kedua disepakati tetapi perlu penambahan index pada perumusan		
13/05/26	Menyampaikan BAB ketiga	13/05/26	Metodanya disepakati dengan <i>Neuro-Symbolic</i>		

Mengetahui Divisi TA

Nama: *Esti Suryani, S.Si, M.Kom.*
 NIP: *197611292008122001*

Proposal Skripsi

**DETEKSI CACAT PCB DENGAN PENJELASAN YANG
FAITHFUL MELALUI ARSITEKTUR NEURO-SYMBOLIC
FASTER R-CNN DAN SPARSE OBLIQUE DECISION TREE**



Disusun Oleh :

HANDI DWI CAHYO

L0122072

FAKULTAS TEKNOLOGI INFORMASI DAN SAINS DATA

UNIVERSITAS SEBELAS MARET

SURAKARTA

2026

PERSETUJUAN

Proposal Skripsi Mahasiswa:

HANDI DWI CAHYO

L0122072

Dengan judul

**DETEKSI CACAT PCB DENGAN PENJELASAN YANG
FAITHFUL MELALUI ARSITEKTUR NEURO-SYMBOLIC
FASTER R-CNN DAN SPARSE OBLIQUE DECISION TREE**

Telah disetujui untuk diseminarkan pada tanggal, *14 April 2026*

Persetujuan Pembimbing (jika ada)

Pembimbing I



Esti Suryani, S.Si., M.Kom.

NIP 197611292008122001

PENGESAHAN

Proposal Skripsi Mahasiswa :

HANDI DWI CAHYO

L0122072

Dengan Judul

DETEKSI CACAT PCB DENGAN PENJELASAN YANG FAITHFUL MELALUI ARSITEKTUR NEURO-SYMBOLIC FASTER R-CNN DAN SPARSE OBLIQUE DECISION TREE

Telah diseminarkan pada tanggal, ...

Susunan Penguji Seminar Proposal

1. Nama Pembimbing 1 (_____ ttd _____)
NIP
2. Nama Pembimbing 2 (_____ ttd _____)
NIP
3. Nama Penguji Utama (_____ ttd _____)
NIP

Mengetahui,

Koordinator Skripsi

Ketua Jurusan

NIP

NIP

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi elektronik meningkatkan kebutuhan terhadap komponen yang andal dan berkualitas tinggi, khususnya *Printed Circuit Board* (PCB). PCB berfungsi sebagai penopang sekaligus penghubung antar-komponen yang menentukan keandalan operasional sistem elektronik. Untuk memenuhi tuntutan keandalan tersebut, PCB kemudian dikembangkan dengan arsitektur yang semakin kompleks. Namun, kompleksitas ini justru meningkatkan risiko munculnya cacat pada PCB akibat kesalahan manusia maupun gangguan mesin selama proses produksi (Chen et al., 2023; Fung et al., 2024). Keberadaan cacat tersebut dapat berdampak pada penurunan kualitas produk, peningkatan biaya produksi, hingga risiko keselamatan manusia (Ali et al., 2023; Fung et al., 2024). Dengan demikian, metode inspeksi menjadi tahapan krusial untuk mendeteksi keberadaan cacat pada PCB.

Tahap inspeksi PCB selama ini bertumpu pada metode konvensional seperti pemeriksaan visual manual dan pengujian kelistrikan. Namun, metode-metode tersebut kerap dinilai tidak efisien, memakan biaya tinggi, dan rentan terhadap kesalahan akibat faktor manusia (Ali et al., 2023; Chen et al., 2023; Fung et al., 2024). Keterbatasan tersebut mendorong pengembangan solusi otomatis berbasis *Artificial Intelligence* (AI), khususnya pendekatan *deep learning*. Berbagai model *deep learning* seperti *You Only Look Once* (YOLO), *Single Shot MultiBox Detector* (SSD), dan *Faster Region-based Convolutional Neural Network* (R-CNN) telah banyak diterapkan untuk deteksi cacat PCB dan menunjukkan performa yang tinggi dalam berbagai studi (Chen et al., 2023). Sebagai contoh, Wang et al. (2024) mengembangkan YOLO-RLC, yaitu YOLOv5 dengan jaringan konvolusi kernel besar residual yang meningkatkan akurasi deteksi cacat PCB. Bahkan, penelitian oleh Fung et al. (2024) menunjukkan bahwa optimasi pada arsitektur *Faster R-CNN* dapat meningkatkan performa deteksi cacat PCB, terutama pada cacat yang berukuran kecil. Hasil beberapa penelitian tersebut menunjukkan bahwa

pendekatan berbasis *deep learning* merupakan pendekatan yang dapat diandalkan untuk tahap inspeksi.

Meskipun pendekatan *deep learning* menunjukkan performa deteksi tinggi, model ini memiliki kelemahan berupa sifat *black-box*, yakni ketidakmampuan model dalam memberikan penjelasan atas setiap keputusan yang dihasilkannya. Padahal, dalam industri manufaktur berisiko tinggi seperti produksi PCB, penjelasan tersebut diperlukan teknisi untuk memvalidasi dan mempertanggungjawabkan hasil deteksi (Tzionis et al., 2026). Tanpa penjelasan yang memadai, proses validasi menjadi sulit dilakukan sehingga berpotensi menurunkan kepercayaan teknisi terhadap model (Tziolas et al., 2025). Oleh karena itu, kemampuan model dalam menjelaskan keputusan (*explainability*) menjadi kebutuhan esensial guna mendukung proses validasi teknisi dalam inspeksi cacat PCB (Saadallah et al., 2022; Chen et al., 2023).

Untuk merespons kebutuhan *explainability* tersebut, *Explainable Artificial Intelligence* (XAI) menjadi pendekatan yang dominan diterapkan dalam sistem inspeksi manufaktur (Tzionis et al., 2026). Pendekatan XAI menghadirkan *explainability* dengan membuat proses pengambilan keputusan model AI dapat ditelusuri dan dipahami. Dalam inspeksi PCB, penelitian Tziolas et al. (2024) menunjukkan bahwa *Deep Shapley Additive Explanations* (SHAP) dan *Gradient-weighted Class Activation Mapping* (Grad-CAM) dapat menyoroti area visual yang memengaruhi keputusan model CNN, sehingga meningkatkan interpretabilitas model bagi teknisi. Penelitian lain oleh Saadallah et al. (2022) menggunakan penjelasan berbasis *heatmap* yang mengungkap fitur-fitur penting pada citra PCB, sehingga membantu teknisi dalam memvalidasi relevansi fitur tersebut terhadap jenis cacat yang terdeteksi. Dengan demikian, XAI mampu memenuhi kebutuhan *explainability* pada inspeksi PCB melalui justifikasi visual atas keputusan model.

Meskipun informatif, metode XAI pada studi tersebut masih memiliki keterbatasan berupa sifat *post-hoc*, yaitu penjelasan yang baru diberikan setelah model *black-box* menghasilkan prediksinya. Mekanisme ini menyebabkan penjelasan yang dihasilkan tidak memenuhi *faithfulness*, yaitu kemampuannya dalam merepresentasikan keputusan model yang sesungguhnya, sehingga

penjelasan tersebut hanyalah berupa perkiraan (Rudin, 2019). Dalam inspeksi PCB, validasi yang bertumpu pada penjelasan yang tidak merepresentasikan keputusan asli model berpotensi mengarahkan teknisi pada keputusan yang salah (Arrighi et al., 2023). Dengan demikian, ketiadaan *faithfulness* dalam penjelasan *post-hoc* justru mengurangi kualitas *explainability* yang dibutuhkan untuk validasi teknisi (Rudin, 2019).

Untuk mengatasi keterbatasan *faithfulness* dalam penjelasan model, arsitektur *neuro-symbolic* hadir dengan menggabungkan ekstraksi fitur dari *deep learning* dan penalaran transparan berbasis simbolik. Dalam arsitektur ini, komponen simbolik terintegrasi langsung ke dalam mekanisme pengambilan keputusan sehingga penjelasan yang dihasilkan bersifat *faithful* (Garcez & Lamb, 2023). Arsitektur ini telah ditunjukkan oleh model *Faster*-LTN yang mengintegrasikan *Faster* R-CNN dengan *Logic Tensor Network* (LTN) untuk mempertahankan performa deteksi sekaligus memberikan penalaran terstruktur (Manigrasso et al., 2021). Sejalan dengan arah tersebut, Hada et al. (2024) serta Kairgeldin dan Carreira-Perpiñán (2025) mengembangkan integrasi CNN dengan *sparse oblique decision tree* (SODT) yang membuat proses pengambilan keputusan model lebih dapat diinterpretasikan dan divisualisasikan. Dengan demikian, ketiga penelitian tersebut berpotensi menghadirkan *faithfulness* sehingga meningkatkan kualitas *explainability* pada inspeksi PCB.

Untuk mewujudkan *explainability* yang memenuhi *faithfulness* tersebut, penelitian ini mengusulkan integrasi *Faster* R-CNN dengan *Sparse Oblique Decision Tree* (SODT) sebagai sistem deteksi cacat berbasis arsitektur *neuro-symbolic*. Dalam usulan ini, *Faster* R-CNN berfungsi sebagai komponen ekstraksi fitur visual dan deteksi objek, sedangkan SODT berperan sebagai komponen penalaran simbolik yang memproses fitur-fitur tersebut menjadi keputusan yang dapat ditelusuri. Integrasi ini dirancang untuk mempertahankan performa deteksi tinggi dari *Faster* R-CNN sekaligus menghadirkan penjelasan yang merepresentasikan proses pengambilan keputusan asli model (*faithfulness*). Dengan demikian, sistem ini ditujukan untuk menghadirkan deteksi PCB yang akurat dan *explainability* yang *faithful* guna mendukung validasi teknisi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana model *deep learning* dapat mempertahankan performa deteksi tinggi pada inspeksi PCB sekaligus mengatasi sifat *black-box* yang menghambat validasi teknisi?
2. Bagaimana arsitektur *neuro-symbolic* yang mengintegrasikan *Faster R-CNN* dengan *Sparse Oblique Decision Tree* (SODT) dapat dikembangkan untuk menghadirkan sistem deteksi cacat PCB yang akurat sekaligus menyediakan *explainability* yang *faithful*?

1.3 Batasan Masalah

Agar penelitian ini tetap terarah dan fokus sesuai dengan tujuan yang telah ditetapkan, ruang lingkup permasalahan dibatasi pada hal-hal sebagai berikut.

1. Objek Penelitian

Penelitian difokuskan pada deteksi enam jenis cacat visual PCB, yaitu *open*, *short*, *mousebite*, *spur*, *pinhole*, dan *spurious copper*, menggunakan pendekatan *deep learning* dan *neuro-symbolic*.

2. Arsitektur Model

Model merupakan integrasi *Faster R-CNN* (mengacu pada implementasi Fung et al., 2024) dengan *Sparse Oblique Decision Tree* (SODT) tanpa modifikasi terhadap struktur internal kedua komponen.

3. Sumber Data

Data yang digunakan berasal dari dataset publik DeepPCB yang memuat 1.500 pasang citra beserta anotasi posisi dan kelas cacat.

4. Metode Evaluasi *Explainability*

Evaluasi kualitas *explainability* dilakukan secara kuantitatif melalui perbandingan dengan Grad-CAM sebagai *baseline post-hoc* yang telah teruji, tanpa melibatkan studi pengguna atau wawancara teknisi.

1.4 Tujuan Penelitian

1. Mengembangkan sistem deteksi cacat PCB berbasis integrasi *Faster R CNN* dan *Sparse Oblique Decision Tree* (SODT) yang mampu mempertahankan

performa deteksi tinggi sekaligus menyediakan penjelasan yang *faithful* guna mendukung proses validasi teknisi.

2. Mengevaluasi apakah sistem yang diusulkan mampu menghasilkan penjelasan yang *faithful* dan lebih baik dibandingkan pendekatan *post-hoc* Grad-CAM.

1.5 Manfaat Penelitian

1. Mendukung proses validasi teknisi di industri manufaktur elektronik melalui sistem deteksi cacat PCB yang tidak hanya akurat, tetapi juga menyediakan penjelasan yang *faithful* dan dapat dipertanggungjawabkan.
2. Memberikan bukti empiris bahwa integrasi Faster R CNN dan *Sparse Oblique Decision Tree* (SODT) mampu mengatasi keterbatasan *faithfulness* yang melekat pada pendekatan XAI *post-hoc*.

BAB II

TINJAUAN PUSTAKA

2.1 Dasar Teori

2.1.1 *Printed Circuit Board (PCB)*

Printed Circuit Board (PCB) adalah komponen fundamental dalam perangkat elektronik yang berfungsi sebagai penyangga mekanis sekaligus penghubung listrik antarkomponen melalui jalur konduktif berpola yang disebut *traces* (Khandpur, 2005). Secara struktural, PCB tersusun atas substrat isolatif berbahan komposit epoksi FR-4 yang dilaminasi dengan lapisan tipis tembaga (*copper foil*) sebagai jalur konduktif (Coombs & Holden, 2016). Di atas lapisan tembaga tersebut, diaplikasikan *solder mask* untuk mencegah oksidasi dan hubungan pendek, serta *silkscreen* untuk penandaan komponen. Dalam proses produksi massal, ketidaksempurnaan pada salah satu lapisan ini dapat menghasilkan anomali visual yang mengganggu fungsi listrik, sehingga tahap inspeksi kualitas menjadi krusial untuk memastikan keandalan produk akhir.

Penentuan kualitas visual PCB di industri mengacu pada standar internasional yang ditetapkan oleh Association Connecting Electronics Industries (IPC), khususnya IPC-A-600 untuk kriteria keberterimaan papan dan IPC-6012 untuk spesifikasi kinerja papan kaku (IPC, 2020; IPC, 2015). Standar ini mengatur batas toleransi geometris yang sangat ketat, misalnya pada reduksi lebar jalur konduktor yang tidak boleh melebihi 20-30% dari lebar desain awal, tergantung kelas produknya. Reduksi yang melebihi ambang batas ini dikategorikan sebagai cacat karena dapat meningkatkan resistansi lokal dan berpotensi menyebabkan kegagalan termal atau diskontinuitas sinyal. Prinsip toleransi dimensional inilah yang mendasari pentingnya sistem inspeksi visual otomatis untuk mendeteksi anomali bentuk (seperti *spur* atau *mousebite*) secara akurat.

Berbagai jenis cacat yang umum teridentifikasi dalam inspeksi visual PCB pada dasarnya merupakan manifestasi dari pelanggaran terhadap prinsip toleransi dimensional tersebut. Tabel 2.1 merangkum enam kategori cacat yang paling sering dijumpai dalam literatur dan praktik industri, beserta implikasi fungsionalnya. Seluruh kategori ini, baik secara langsung maupun tidak langsung,

merepresentasikan deviasi dari dimensi nominal jalur atau pelanggaran terhadap integritas dielektrik papan.

Tabel 2.1 Kategori Cacat Visual Umum pada PCB dan Implikasi Fungsionalnya

Jenis Cacat	Definisi Visual	Implikasi Fungsional
<i>Open</i>	Jalur tembaga terputus atau tidak tersambung sempurna	Diskontinuitas aliran arus, perangkat tidak berfungsi
<i>Short</i>	Dua jalur atau lebih yang seharusnya terpisah menjadi tersambung secara tidak sengaja	Hubungan pendek, kerusakan komponen, risiko kebakaran
<i>Mousebite</i>	Cekungan atau gerigi pada tepi jalur akibat proses pengeboran atau pemotongan yang tidak presisi	Reduksi lebar jalur lokal, peningkatan resistansi, potensi titik panas (<i>hotspot</i>)
<i>Spur</i>	Tonjolan tembaga kecil yang menonjol keluar dari tepi jalur utama	Reduksi jarak antar konduktor, meningkatkan risiko <i>short</i>
<i>Pinhole</i>	Lubang kecil melingkar di dalam area konduktif akibat gelembung udara saat proses <i>etching</i>	Reduksi luas penampang konduktor, peningkatan resistansi lokal
<i>Spurious Copper</i>	Tembaga liar yang muncul di area non-konduktif, bukan bagian dari desain rangkaian	Reduksi jarak isolasi antar jalur, potensi jalur konduktif parasitik

Berdasarkan Tabel 2.1, dapat diamati bahwa *open*, *mousebite*, dan *pinhole* secara langsung berkaitan dengan pengurangan material konduktif (reduksi lebar atau luas penampang), yang diatur oleh prinsip toleransi reduksi maksimum 20–30% pada standar IPC. Sementara itu, *short*, *spur*, dan *spurious copper* berkaitan dengan penambahan material yang tidak diinginkan, yang berdampak pada pelanggaran jarak minimum antar konduktor. Pendekatan deteksi visual yang akurat menjadi esensial untuk mengidentifikasi dan mengklasifikasikan

anomali tersebut guna menjamin kualitas produk sesuai standar industri yang berlaku.

2.1.2 Computer Vision

Computer Vision adalah cabang ilmu komputer yang bertujuan mengembangkan sistem komputasional agar mampu mengekstrak informasi bermakna dari citra digital secara otomatis (Szeliski, 2022). Disiplin ini berupaya meniru kemampuan sistem visual manusia dalam memahami konten visual melalui analisis data piksel yang ditangkap oleh sensor. Berbeda dengan pengolahan citra konvensional yang berfokus pada peningkatan kualitas visual, *computer vision* bertujuan menghasilkan deskripsi simbolik atau keputusan semantik tentang isi citra (Prince, 2023).

Ruang lingkup computer vision mencakup tiga tugas utama yang dibedakan berdasarkan tingkat granularitas keluarannya.

1. **Klasifikasi Citra** (*Image Classification*) menetapkan satu label kelas untuk keseluruhan citra tanpa memperhatikan posisi spasial objek di dalamnya (Prince, 2023).
2. **Deteksi Objek** (*Object Detection*) mengidentifikasi keberadaan satu atau lebih objek dalam citra, menentukan kategori masing-masing, serta melokalisasi posisinya dalam bentuk *bounding box* persegi panjang (Szeliski, 2022).
3. **Segmentasi Citra** (*Image Segmentation*) memberikan label kelas pada setiap piksel untuk menghasilkan delineasi batas objek yang lebih presisi dibandingkan *bounding box* (Minaee et al., 2021).

Ketiga tugas utama dalam *computer vision* tersebut secara visual dapat dibedakan melalui tingkat granularitas output-nya, sebagaimana diilustrasikan pada Gambar 2.1.

Klasifikasi



Deteksi Objek




Segmentasi



Gambar 2.1 Perbandingan Klasifikasi, Deteksi Objek, dan Segmentasi

Deteksi objek memiliki tingkat kompleksitas yang lebih tinggi dibandingkan klasifikasi citra karena menuntut model untuk secara simultan melakukan dua sub tugas: klasifikasi untuk menentukan kategori objek, dan **regresi** untuk menentukan koordinat spasial objek dalam bentuk *bounding box* persegi panjang (Szeliski, 2022). Kemampuan model untuk menghasilkan *bounding box* yang akurat, baik dalam format koordinat sudut maupun titik pusat, menjadi fondasi penting bagi sistem inspeksi visual otomatis. Ilustrasi mengenai representasi *bounding box* tersebut disajikan pada Gambar 2.2.




Gambar 2.2 Anatomi dan Representasi Koordinat Bounding Box

2.1.3 Deep Learning

Deep learning adalah cabang dari *machine learning* yang memungkinkan komputer untuk belajar dari pengalaman dan memahami dunia dalam bentuk hierarki konsep (Goodfellow et al., 2016). Istilah "dalam" (*deep*) merujuk pada banyaknya lapisan (*layers*) pemrosesan non-linear yang tersusun secara bertingkat,

di mana setiap lapisan menggunakan keluaran dari lapisan sebelumnya sebagai masukan (Han et al., 2017). Arsitektur berlapis ini memungkinkan model untuk mempelajari representasi data secara bertahap, dimulai dari fitur-fitur sederhana pada lapisan awal hingga fitur-fitur yang semakin abstrak dan kompleks pada lapisan yang lebih dalam. Kemampuan untuk mempelajari hierarki representasi fitur inilah yang menjadi karakteristik pembeda utama *deep learning* dari pendekatan *machine learning* konvensional.

Perbedaan fundamental antara *deep learning* dan *machine learning* tradisional terletak pada pendekatan terhadap ekstraksi fitur. Pada paradigma pembelajaran mesin konvensional, rekayasa fitur (*feature engineering*) dilakukan secara manual oleh praktisi yang harus mengidentifikasi dan mengekstrak fitur-fitur relevan dari data mentah sebelum proses pelatihan model dimulai. Sebaliknya, *deep learning* melakukan pembelajaran fitur (*feature learning*) secara otomatis dan langsung dari data mentah tanpa memerlukan intervensi manual yang ekstensif. Dalam alur kerja *deep learning*, data mentah seperti piksel citra dapat langsung dimasukkan ke dalam jaringan, dan representasi fitur yang memiliki daya prediktif akan dipelajari secara simultan selama proses pelatihan. Kemampuan inilah yang menjadikan *deep learning* sangat efektif dalam menangani data berdimensi tinggi dan tidak terstruktur seperti citra digital. Perbandingan alur kerja antara paradigma *machine learning* konvensional dan *deep learning* dalam melakukan ekstraksi fitur dan klasifikasi diilustrasikan pada Gambar 2.3.



Gambar 2.3 Perbedaan cara kerja *Machine Learning* dan *Deep Learning*

Mekanisme pelatihan dalam *deep learning* mengandalkan dua algoritma fundamental yang bekerja secara berpasangan. Propagasi maju (*forward propagation*) merupakan proses mengalirkan data masukan (*input*) melalui seluruh lapisan jaringan secara berurutan untuk menghasilkan prediksi akhir. Pada setiap lapisan, dilakukan operasi perkalian antara masukan dengan bobot (*weight*) yang sesuai, diikuti dengan penjumlahan bias, kemudian dilewatkan ke fungsi aktivasi non-linear. Proses ini dinyatakan sebagai Persamaan 2.1.

$$a^{(l)} = f(W^{(l)}a^{(l-1)} + b^{(l)}) \quad (2.1)$$

dengan $a^{(l)}$ adalah keluaran (*output*) pada lapisan ke- l , $W^{(l)}$ adalah matriks bobot, $b^{(l)}$ adalah vektor bias, dan f adalah fungsi aktivasi (Goodfellow et al., 2016). Fungsi aktivasi yang paling umum digunakan dalam jaringan modern adalah *Rectified Linear Unit* (ReLU) yang didefinisikan pada Persamaan 2.2.

$$\text{ReLU}(x) = \max(0, x) \quad (2.2)$$

ReLU bersifat non-linear namun secara komputasi sangat efisien, serta mampu mengatasi masalah *vanishing gradient* yang sering terjadi pada fungsi aktivasi sigmoid atau tanh (LeCun et al., 2015).

Setelah keluaran akhir diperoleh, selisih antara prediksi dan nilai sebenarnya diukur menggunakan *loss function*. Untuk tugas klasifikasi multi-kelas seperti deteksi cacat PCB, fungsi kerugian yang paling umum digunakan adalah *Cross-Entropy Loss* yang didefinisikan pada Persamaan 2.3.

$$\mathcal{L} = - \sum_{c=1}^C y_c \log(\hat{y}_c) \quad (2.3)$$


dengan C adalah jumlah kelas, y_c adalah label sebenarnya dalam bentuk *one-hot encoding* (1 untuk kelas benar, 0 untuk lainnya), dan $\hat{y}_c$ adalah probabilitas prediksi untuk kelas c . Fungsi ini mengukur divergensi antara distribusi probabilitas prediksi model dan distribusi sebenarnya, serta memberikan penalti yang besar ketika model sangat yakin namun salah (Goodfellow et al., 2016).

Selanjutnya, algoritma propagasi mundur (*backpropagation*) menghitung gradien dari *loss function* terhadap setiap parameter jaringan dengan menerapkan aturan rantai (*chain rule*) kalkulus secara efisien dari lapisan keluaran menuju

lapisan masukan (LeCun et al., 2015). Gradien yang diperoleh kemudian digunakan oleh algoritma optimasi penurunan gradien stokastik (*stochastic gradient descent*/SGD) untuk memperbarui nilai parameter ke arah yang meminimalkan fungsi kerugian. Aturan pembaruan bobot dinyatakan pada Persamaan 2.4.

$$w \leftarrow w - \eta \frac{\partial \mathcal{L}}{\partial w} \quad (2.4)$$

dengan w adalah parameter bobot, η adalah laju pembelajaran (*learning rate*) yang mengontrol besarnya langkah pembaruan, dan $\frac{\partial \mathcal{L}}{\partial w}$ adalah gradien fungsi kerugian terhadap bobot tersebut (Goodfellow et al., 2016). Proses ini diulangi secara iteratif pada seluruh data pelatihan hingga model mencapai konvergensi atau performa yang diinginkan. Secara sistematis, siklus pelatihan *deep learning* yang melibatkan alur *forward propagation* untuk menghasilkan prediksi dan *backward propagation* untuk pembaruan parameter diilustrasikan pada Gambar 2.4




Gambar 2.4 Diagram Alur Kerja Siklus Pelatihan Jaringan Saraf Tiruan

2.1.4 Convolution Neural Network (CNN)

Convolutional Neural Network (CNN) adalah kelas khusus dari jaringan saraf tiruan yang dirancang secara spesifik untuk memproses data bertopologi grid, seperti citra digital dua dimensi yang tersusun atas matriks piksel (Goodfellow et al., 2016; LeCun et al., 2015). Berbeda dengan jaringan saraf konvensional yang menghubungkan setiap neuron pada suatu lapisan ke seluruh neuron pada lapisan berikutnya (*fully connected*), CNN memanfaatkan struktur spasial data masukan

melalui dua mekanisme utama, yaitu konektivitas lokal (*local connectivity*) dan pembagian parameter (*parameter sharing*) (LeCun et al., 2015). Kedua mekanisme ini memungkinkan CNN untuk mengekstrak fitur visual secara efisien dengan jumlah parameter yang jauh lebih sedikit, sekaligus mempertahankan invariansi terhadap pergeseran spasial objek dalam citra. Keunggulan CNN dalam mengenali pola visual secara otomatis dan hierarkis telah menjadikannya tulang punggung berbagai tugas *computer vision* modern, termasuk klasifikasi citra, deteksi objek, dan segmentasi semantik. Representasi arsitektur umum CNN yang terdiri dari tahapan ekstraksi fitur dan klasifikasi disajikan pada Gambar 2.5.



Gambar 2.5 Ilustrasi Arsitektur *Convolutional Neural Network* (CNN)

Arsitektur CNN tersusun atas beberapa jenis lapisan yang masing-masing menjalankan fungsi spesifik dalam membangun representasi fitur dari data masukan (*input*). Lapisan pertama dan paling fundamental adalah lapisan konvolusi (*convolutional layer*), yang berfungsi mengekstrak fitur lokal dari citra melalui operasi konvolusi antara sekumpulan filter (kernel) yang dapat dipelajari dengan wilayah lokal pada peta fitur masukan (Zhao et al., 2024). Setiap filter mendeteksi pola visual tertentu seperti tepi, sudut, atau tekstur. Operasi konvolusi dua dimensi antara citra masukan I dan kernel K secara matematis didefinisikan pada Persamaan 2.5.

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (2.5)$$

dengan (i, j) adalah koordinat piksel keluaran, serta m dan n adalah indeks yang merentang pada dimensi kernel K (Goodfellow et al., 2016). Setelah operasi konvolusi, fungsi aktivasi non-linear diterapkan pada setiap elemen peta fitur untuk

memperkenalkan sifat non-linear ke dalam jaringan. Fungsi aktivasi yang paling umum digunakan adalah ReLU yang telah dijelaskan pada subbab sebelumnya.

Lapisan berikutnya adalah lapisan *pooling* (*pooling layer*), yang berfungsi mereduksi dimensi spasial peta fitur melalui operasi *downsampling*. Operasi pooling yang paling umum adalah *max pooling*, yang mengambil nilai maksimum dalam suatu jendela spasial. Untuk jendela pooling berukuran $p \times p$ dengan stride s , operasi *max pooling* didefinisikan sebagai persamaan 2.6.

$$y_{i,j} = \max_{m,n \in \{0, \dots, p-1\}} x_{i \cdot s + m, j \cdot s + n} \quad (2.6)$$

dengan x adalah peta fitur masukan dan y adalah peta fitur keluaran (Zhao et al., 2024). Reduksi dimensi ini tidak hanya mengurangi beban komputasi dan jumlah parameter, tetapi juga meningkatkan invariansi model terhadap distorsi dan pergeseran kecil pada fitur yang terdeteksi.

Setelah serangkaian lapisan konvolusi dan *pooling*, peta fitur yang dihasilkan umumnya dipipihkan (*flatten*) menjadi vektor satu dimensi dan diteruskan ke *fully connected layer*. Lapisan ini berfungsi mengintegrasikan fitur-fitur tingkat tinggi yang telah diekstrak oleh lapisan-lapisan sebelumnya untuk menghasilkan keputusan akhir, seperti probabilitas kelas pada tugas klasifikasi atau koordinat *bounding box* pada tugas deteksi objek. Pada lapisan keluaran akhir, fungsi *softmax* digunakan untuk menghasilkan distribusi probabilitas atas kelas-kelas yang tersedia. Fungsi softmax untuk kelas ke- k dari total C kelas didefinisikan sebagai Persamaan 2.7.

$$\text{softmax}(z_k) = \frac{e^{z_k}}{\sum_{j=1}^C e^{z_j}} \quad (2.7)$$


dengan z_k adalah skor mentah (logit) untuk kelas ke- k (Goodfellow et al., 2016).

2.1.5 Faster R-CNN

Faster R-CNN adalah arsitektur deteksi objek dua tahap yang mengintegrasikan seluruh alur deteksi ke dalam satu jaringan konvolusional terpadu yang dapat dilatih secara ujung ke ujung (Ren et al., 2015). Komponen utamanya terdiri atas *backbone network* untuk mengekstrak peta fitur dari citra masukan, *Region Proposal Network* (RPN) untuk menghasilkan kandidat area

objek, *RoI Pooling* untuk menyeragamkan dimensi fitur dari setiap kandidat, serta jaringan klasifikasi dan regresi yang menentukan kategori dan koordinat akhir setiap objek. Inovasi utama Faster R-CNN terletak pada RPN yang sepenuhnya menggantikan algoritma proposal eksternal seperti *Selective Search*, sehingga seluruh komponen dapat berbagi fitur konvolusional dan dilatih secara simultan (Ren et al., 2015).

Mekanisme kerja dari modul-modul penyusun arsitektur Faster R-CNN standar diilustrasikan pada Gambar 2.6, dengan penjelasan yang lebih terperinci sebagai berikut:



Gambar 2.6 Arsitektur Faster R-CNN Standar

1. Region Proposal Network (RPN)

RPN bekerja dengan menggeser jendela kecil berukuran 3×3 di atas peta fitur. Pada setiap posisi, RPN memprediksi beberapa *anchor boxes* yaitu kotak referensi dengan berbagai skala dan rasio aspek. Untuk setiap *anchor*, RPN menghasilkan skor objektivitas p melalui lapisan *softmax* dua kelas serta empat koordinat penyempurnaan melalui lapisan regresi. Transformasi dari *anchor box* (x_a, y_a, w_a, h_a) ke *bounding box* yang diprediksi dirumuskan persamaan berikut (Ren et al., 2015):

$$t_x = \frac{x - x_a}{w_a} \quad (2.8)$$

$$t_y = \frac{y - y_a}{h_a} \quad (2.9)$$

$$t_w = \log \frac{w}{w_a} \quad (2.10)$$

$$t_h = \log \frac{h}{h_a} \quad (2.11)$$

Fungsi kerugian RPN adalah *multi-task loss* yang menggabungkan kerugian klasifikasi dan regresi yang didefinisikan pada Persamaan 2.12 (Ren et al., 2015).

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (2.12)$$

dengan p_i^* adalah label *ground truth* yang bernilai 1 untuk *anchor* positif dan 0 untuk *anchor* negatif, L_{cls} adalah *binary cross-entropy loss*, dan L_{reg} adalah *Smooth L1 Loss* yang didefinisikan pada Persamaan 2.23 (Girshick, 2015).

$$\text{smooth}_{L_1}(x) = \begin{cases} 0,5x^2, & \text{jika } |x| < 1 \\ |x| - 0,5, & \text{lainnya} \end{cases} \quad (2.13)$$


2. RoI Pooling

RoI Pooling menerima peta fitur dari *backbone* dan proposal area dari RPN, kemudian mengekstrak fitur dengan dimensi seragam dari setiap proposal yang ukurannya bervariasi. Mekanisme ini membagi setiap proposal ke dalam grid spasial tetap berukuran $H \times W$ yang umumnya 7×7 dan menerapkan operasi *max pooling* pada setiap sel grid. Secara matematis, untuk setiap sel (i, j) pada proposal, nilai keluarannya didefinisikan pada Persamaan 2.14 (Girshick, 2015).

$$y_{i,j} = \max_{(p,q) \in \text{bin}(i,j)} x_{p,q} \quad (2.14)$$

dengan $\text{bin}(i, j)$ adalah himpunan piksel pada proposal yang termasuk dalam sel grid ke- (i, j) . Vektor fitur hasil RoI Pooling kemudian dipipihkan dan diteruskan ke lapisan *fully connected* untuk klasifikasi akhir dan regresi *bounding box* kelas spesifik. Jaringan klasifikasi akhir menggunakan fungsi kerugian serupa dengan RPN yaitu kombinasi *softmax cross-entropy loss* untuk klasifikasi multi-kelas dan *Smooth L1 Loss* untuk regresi *bounding box*.

Guna mengoptimalkan deteksi cacat mikro, arsitektur ini dimodifikasi dengan modul *PSPyramid* dan *SF Attention* (Fung et al., 2024) , sebagaimana diilustrasikan pada Gambar 2.7.



Gambar 2.7 Arsitektur modifikasi Faster R-CNN dengan SF-PSPyramid

1. Feature Pyramid Network (FPN)

FPN merupakan arsitektur tambahan yang memperkuat Faster R-CNN dalam mendeteksi objek pada berbagai skala. FPN membangun piramida fitur multi-skala dengan tiga jalur utama. Jalur *bottom-up* merupakan propagasi maju standar *backbone* CNN yang menghasilkan hierarki fitur $\{C_2, C_3, C_4, C_5\}$ dengan resolusi yang semakin menurun. Jalur *top-down* melakukan *upsampling* fitur resolusi rendah untuk mengembalikan resolusi spasial. Koneksi lateral menggabungkan fitur dari jalur *bottom-up* dengan fitur yang telah di-*upsample* melalui konvolusi 1×1 untuk menyamakan jumlah kanal. Tingkat piramida $\{P_2, P_3, P_4, P_5\}$ dihitung secara rekursif seperti yang ditunjukkan pada Persamaan 2.15 (Lin et al., 2017).

$$P_l = \text{Conv}_{1 \times 1}(C_l) + \text{Upsample}(P_{l+1}) \quad (2.15)$$

2. Pixel Shuffle Pyramid (PSPyramid)

PSPyramid adalah modifikasi FPN yang menggunakan operasi *pixel shuffle* untuk meningkatkan resolusi spasial peta fitur. Berbeda dari *upsampling* konvensional seperti interpolasi bilinear, *pixel shuffle* mengatur ulang elemen dari tensor berdimensi $C \times r^2 \times H \times W$ menjadi tensor

berdimensi $C \times Hr \times Wr$ dengan faktor skala r (Fung et al., 2024). Operasi ini secara matematis dinyatakan dengan Persamaan 2.16 (Shi et al., 2016).

$$PS(T)_{c,i \cdot r + x, j \cdot r + y} = T_{c \cdot r^2 + x \cdot r + y, i, j} \quad (2.16)$$

3. Selective Feature Attention (SF Attention)

SF Attention adalah modul atensi yang menyempurnakan kualitas peta fitur piramida. *SF Attention* mengintegrasikan mekanisme *channel attention* dan *spatial attention* untuk memboboti fitur yang paling informatif (Fung et al., 2024). Modul ini memproses peta fitur masukan melalui operasi *global average pooling* untuk memperoleh statistik kanal, diikuti oleh lapisan *fully connected* dengan fungsi aktivasi sigmoid yang menghasilkan bobot atensi per kanal. Bobot ini kemudian mengalikan peta fitur asli secara kanal demi kanal untuk memperkuat fitur yang relevan dan meredam derau latar belakang. Proses ini memungkinkan model untuk secara adaptif berfokus pada fitur visual yang paling diskriminatif seperti tekstur atau bentuk cacat mikro pada PCB.

2.1.6 Explainable Artificial Intelligence (XAI)

Explainable Artificial Intelligence (XAI) adalah bidang studi yang bertujuan mengembangkan metode dan teknik agar proses pengambilan keputusan model kecerdasan buatan dapat dipahami oleh manusia (Arrieta et al., 2020). Kehadiran XAI didorong oleh kebutuhan transparansi dan akuntabilitas dalam sistem AI, terutama pada model deep learning yang kompleks dan bersifat *black-box* (Samek et al., 2019). Secara garis besar, metode XAI diklasifikasikan ke dalam dua pendekatan utama. Pendekatan *post-hoc* diterapkan setelah model selesai melakukan inferensi untuk memberikan penjelasan tanpa mengubah struktur internal model, contohnya LIME, SHAP, dan Grad-CAM. Sebaliknya, pendekatan *ante-hoc* membangun interpretabilitas langsung ke dalam struktur model sehingga bersifat transparan secara inheren, seperti pohon keputusan, model *linear*, dan arsitektur neuro-simbolik (Guidotti et al., 2021; Arrieta et al., 2020).

Dalam konteks data visual seperti citra, metode *post-hoc* yang menghasilkan penjelasan berbasis peta panas (*heatmap*) menjadi pilihan umum karena

kemampuannya menyoroti wilayah piksel yang paling berkontribusi terhadap keputusan model. Metode-metode seperti *LIME*, SHAP, dan Grad-CAM termasuk dalam kategori ini, dengan masing-masing pendekatan memiliki mekanisme atribusi yang berbeda. Di antaranya, Grad-CAM telah banyak digunakan karena kemampuannya menghasilkan peta lokalisasi kelas-spesifik tanpa memerlukan modifikasi arsitektur atau pelatihan ulang model (Selvaraju et al., 2017).


Grad-CAM bekerja dengan memanfaatkan gradien dari skor kelas target yang mengalir ke lapisan konvolusional terakhir untuk menghasilkan peta lokalisasi (Selvaraju et al., 2017). Bobot kepentingan α_k^c untuk setiap peta fitur A^k terhadap kelas target c dihitung melalui operasi global *average pooling* terhadap gradien skor kelas y^c terhadap aktivasi peta fitur yang ditunjukkan pada Persamaan 2.17.

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (2.17)$$

dengan Z adalah jumlah piksel pada peta fitur dan (i, j) adalah indeks spasial. *Heatmap* Grad-CAM untuk kelas c diperoleh melalui kombinasi linear terbobot dari peta fitur yang diikuti oleh fungsi aktivasi ReLU yang didefinisikan pada Persamaan 2.18.

$$L_{Grad-CAM}^c = ReLU \left(\sum_k \alpha_k^c A^k \right) \quad (2.18)$$


Heatmap yang dihasilkan kemudian di-*upsample* ke ukuran citra masukan dan ditumpangkan pada citra asli, dengan intensitas warna yang menunjukkan tingkat kepentingan wilayah tersebut terhadap prediksi kelas c (Selvaraju et al., 2017).



Gambar 2.8 Hasil penjelasan dari Grad-CAM (Selvaraju et al., 2017).

2.1.7 Neuro-Symbolic AI (NeSy)

Neuro-Symbolic AI (NeSy) adalah paradigma dalam kecerdasan buatan yang mengintegrasikan dua pendekatan yang secara tradisional terpisah, yaitu jaringan saraf tiruan (*neural networks*) untuk pembelajaran statistik dari data dan penalaran simbolik (*symbolic reasoning*) untuk manipulasi pengetahuan eksplisit berbasis logika (d'Avila Garcez & Lamb, 2023). Integrasi kedua pendekatan tersebut, sebagaimana diilustrasikan pada Gambar 2.9, bertujuan menggabungkan kekuatan kedua paradigma: kemampuan jaringan saraf dalam mempelajari pola kompleks dari data mentah berdimensi tinggi, serta transparansi, interpretabilitas, dan penalaran sistematis yang dimiliki oleh sistem simbolik (Hitzler & Sarker, 2022). Dalam arsitektur neuro-simbolik, komponen neural biasanya berperan sebagai ekstraktor fitur yang mengubah data mentah (misalnya citra) menjadi representasi numerik, sementara komponen simbolik memproses representasi tersebut melalui aturan logika atau struktur pengetahuan yang dapat ditelusuri dan diverifikasi secara eksplisit.




Gambar 2.9 Arsitektur *Neuro-Symbolic*

Keunggulan utama pendekatan neuro-simbolik dalam konteks *explainability* adalah kemampuannya menghasilkan penjelasan yang bersifat *faithful* (setia), yaitu penjelasan yang secara langsung merefleksikan proses pengambilan keputusan internal model, bukan sekadar aproksimasi *post-hoc* (Rudin, 2019). Hal ini dimungkinkan karena komponen simbolik terintegrasi langsung ke dalam mekanisme inferensi model, sehingga setiap keputusan dapat dirunut melalui aturan logika yang eksplisit. Berbagai arsitektur neuro-simbolik telah dikembangkan, seperti Logic Tensor Networks (LTN) yang mengintegrasikan logika orde pertama ke dalam pembelajaran mendalam, serta hibrida CNN dengan pohon keputusan yang menggantikan lapisan klasifikasi *black-box* dengan struktur pohon yang transparan (Manigrasso et al., 2021; Hada et al., 2024). Pendekatan yang disebut terakhir menjadi fondasi bagi penggunaan Sparse Oblique Decision Tree (SODT) sebagai komponen simbolik yang akan dibahas pada subbab berikutnya.

2.1.8 Sparse Oblique Decision Tree (SODT)

Sparse Oblique Decision Tree (SODT) adalah varian pohon keputusan yang pada setiap simpul internalnya menggunakan pemisahan miring (*oblique split*) berupa kombinasi linear dari fitur masukan (Hada et al., 2024). Mekanisme pemisahan ini secara fundamental berbeda dengan pohon aksial konvensional, sebagaimana diilustrasikan dalam perbandingan ruang fitur pada Gambar 2.10. Perbedaannya dari pohon aksial konvensional yang hanya menguji satu fitur, pemisahan miring memungkinkan partisi ruang fitur yang tidak terbatas pada

orientasi ortogonal, sehingga dapat menghasilkan batas keputusan yang lebih efisien dengan struktur pohon yang lebih dangkal.



Gambar 2.10 Perbedaan Pohon Aksial dan Oblique

Suatu titik data $x \in \mathbb{R}^D$ akan diarahkan ke cabang kanan pada suatu simpul jika memenuhi kondisi pertidaksamaan 2.19.

$$w^T x + b \geq 0 \quad (2.19)$$


dengan $w \in \mathbb{R}^D$ adalah vektor bobot, b adalah bias, dan D adalah dimensi fitur masukan (Hada et al., 2024). Jika kondisi tidak terpenuhi, data diarahkan ke cabang kiri. Vektor bobot w dan bias b pada setiap simpul dipelajari selama pelatihan.

Istilah *sparse* (jarang) merujuk pada penerapan regularisasi L_1 terhadap vektor bobot w pada setiap simpul. Regularisasi ini memaksa banyak elemen bobot bernilai nol, sehingga setiap percabangan hanya bergantung pada sebagian kecil fitur yang benar-benar informatif (Carreira-Perpiñán & Tavallali, 2018). Arsitektur internal simpul yang mengintegrasikan mekanisme *routing* biner dan sifat *sparse* ini diilustrasikan pada Gambar 2.11. Fungsi objektif yang diminimalkan pada setiap simpul selama pelatihan dinyatakan sebagai Persamaan 2.20.

$$E(w, b) = L(w, b) + \lambda \|w\|_1 \quad (2.20)$$

dengan $L(w, b)$ adalah fungsi kerugian klasifikasi (misalnya *cross-entropy*) dan λ adalah *hyperparameter* yang mengontrol kekuatan regularisasi (Carreira-Perpiñán & Tavallali, 2018). Sifat *sparse* inilah yang menjadi kunci interpretabilitas SODT, karena pengguna dapat dengan mudah mengidentifikasi

fitur mana saja yang berperan dalam suatu keputusan hanya dengan melihat bobot yang tidak nol.



Gambar 2.11 Komputasi internal node pada SODT

Pelatihan SODT dilakukan menggunakan algoritma *Tree Alternating Optimization* (TAO), yang memungkinkan optimasi pohon secara global tanpa terjebak dalam solusi lokal sebagaimana yang kerap terjadi pada algoritma *greedy* seperti CART (Carreira-Perpiñán & Tavallali, 2018). TAO didasarkan pada dekomposisi fungsi kerugian total pohon $E(\Theta)$ terhadap parameter seluruh simpul Θ . Dengan memanfaatkan struktur pohon, fungsi *total loss* dapat diuraikan menjadi penjumlahan atas himpunan bagian yang saling lepas (*disjoint subsets*). Untuk suatu himpunan simpul yang tidak saling terkait secara hierarkis (misalnya semua simpul pada kedalaman yang sama), parameter-parameter tersebut dapat dioptimalkan secara simultan dengan membekukan parameter simpul lainnya. Secara formal, misalkan Θ_i adalah parameter pada simpul ke- i dan Θ_{-i} adalah parameter seluruh simpul lainnya yang dibekukan, maka submasalah optimasi pada simpul ke- i dinyatakan sebagai Persamaan 2.21.

$$\theta_i^{new} = \arg \min_{\theta_i} E(\theta_i; \theta_{-i}) \quad (2.21)$$

Pembaruan ini dijamin tidak menaikkan nilai fungsi kerugian total, sehingga TAO menjamin penurunan fungsi objektif secara monoton pada setiap iterasi hingga konvergensi tercapai (Carreira-Perpiñán & Tavallali, 2018).

Dalam paradigma neuro-simbolik, SODT dapat diintegrasikan dengan CNN untuk menggantikan lapisan klasifikasi *black-box* yang umumnya berupa *fully connected layer* dengan *softmax* (Kairgeldin & Carreira-Perpiñán, 2025). CNN

berfungsi sebagai ekstraktor fitur yang mengubah data mentah menjadi representasi numerik berdimensi tinggi, sementara SODT bertindak sebagai pengambil keputusan akhir yang transparan. Setiap lintasan dari akar hingga daun pada SODT merepresentasikan aturan logika yang dapat ditelusuri dan diverifikasi, sementara bobot *sparse* pada simpul internal memungkinkan identifikasi fitur spesifik yang mendasari klasifikasi tertentu. Kombinasi ini menawarkan keseimbangan antara kekuatan representasional deep learning dan kemampuan penalaran eksplisit yang menjadi ciri sistem simbolik.

2.1.9 Metrik Evaluasi

1. Metrik Evaluasi Deteksi Objek

Evaluasi kinerja model deteksi objek bertumpu pada konsep tumpang tindih antara area prediksi dan area kebenaran dasar. Intersection over Union (IoU) mengukur rasio antara luas irisan terhadap luas gabungan dari *bounding box* prediksi dan *bounding box* aktual, yang dinyatakan sebagai Persamaan 2.22.

$$\text{IoU} = \frac{\text{Area Prediksi} \cap \text{Area Ground Truth}}{\text{Area Prediksi} \cup \text{Area Ground Truth}} \quad (2.22)$$

Sebuah prediksi dinyatakan sebagai True Positive (TP) apabila IoU melebihi ambang batas tertentu, umumnya 0,5. Sebaliknya, prediksi dengan IoU di bawah ambang batas dikategorikan sebagai False Positive (FP), sedangkan objek aktual yang tidak terdeteksi disebut False Negative (FN) (Padilla et al., 2021). Berdasarkan kategori tersebut, Precision dan Recall didefinisikan sebagai Persamaan 2.23 dan Persamaan 2.24.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.23)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.24)$$

Precision mencerminkan seberapa akurat model dalam menghasilkan prediksi, sementara Recall mencerminkan seberapa lengkap model menemukan seluruh objek yang ada (Powers, 2011). Kedua metrik ini bersifat tarik-ulur, sehingga evaluasi yang komprehensif memerlukan metrik yang mengintegrasikan keduanya.

Average Precision (AP) merupakan luasan area di bawah kurva Precision-Recall yang dihitung pada berbagai tingkat ambang keyakinan. Secara matematis, AP didefinisikan sebagai Persamaan 2.25.

$$AP = \int_0^1 \text{Precision}(\text{Recall}) d(\text{Recall}) \quad (2.25)$$

Dalam praktiknya, AP dihitung melalui interpolasi 11 titik atau interpolasi semua titik data pada kurva Precision-Recall (Everingham et al., 2010). Sementara itu, Mean Average Precision (mAP) adalah rata-rata dari nilai AP yang dihitung pada seluruh K kelas objek dalam dataset yang ditunjukkan pada Persamaan 2.26.

$$mAP = \frac{1}{K} \sum_{i=1}^K AP_i \quad (2.26)$$

mAP telah menjadi standar baku dalam evaluasi model deteksi objek karena kemampuannya mengakomodasi variasi jumlah kelas, ketidakseimbangan data, serta perbedaan tingkat keyakinan prediksi antar model yang dibandingkan (Padilla et al., 2021). Nilai mAP berkisar antara 0 hingga 1, dengan nilai yang lebih tinggi mengindikasikan performa deteksi yang lebih baik secara keseluruhan.

2. Metrik Evaluasi *Explainability*

Evaluasi terhadap metode *Explainable AI* (XAI) bertujuan untuk mengukur kualitas, keandalan, dan efektivitas penjelasan yang dihasilkan oleh suatu model. Secara garis besar, metrik evaluasi XAI dikelompokkan ke dalam dua kategori: *functionally-grounded* (kuantitatif, otomatis) dan *human-centered* (subjektif, melibatkan manusia) (Canha et al., 2025; Hoffman et al., 2018). Dalam domain kuantitatif, properti penjelasan yang telah diformalkan meliputi representasi asli terhadap proses model (*faithfulness*), stabilitas (*robustness*), kesederhanaan (*complexity*), kelengkapan (*completeness*), konsistensi (*continuity*), daya pembeda (*contrastivity*), dan kesesuaian spasial (*localization*) (Nauta et al., 2023; Captum, 2025). Di antara properti tersebut, *faithfulness* dan *localization* merupakan dua dimensi paling krusial untuk inspeksi visual karena bersifat komplementer: *faithfulness* menjamin

kejujuran penjelasan terhadap model, sedangkan localization menjamin kebenaran semantiknya terhadap *ground truth*.

Evaluasi *faithfulness* dilakukan menggunakan *Deletion AUC* dan *Insertion AUC* (Petsiuk et al., 2018). Kedua metrik ini menghitung luas di bawah kurva perubahan skor prediksi model seiring modifikasi bertahap pada citra. Jika area citra dimodifikasi dalam K tahap dan s_k adalah skor prediksi ternormalisasi pada tahap ke- k , maka nilai AUC dihitung dengan aturan trapesium ditunjukkan oleh Persamaan 2.27.

$$AUC = \sum_{k=1}^{K-1} \frac{(s_k + s_{k+1})}{2} \cdot \Delta x_k \quad (2.27)$$

dengan Δx_k adalah lebar langkah proporsi area yang dimodifikasi. *Deletion AUC* mengukur penurunan skor saat area penting dihapus; nilai rendah menunjukkan model sangat bergantung pada area tersebut. *Insertion AUC* mengukur peningkatan skor saat area penting disisipkan ke citra kabur; nilai tinggi mengonfirmasi kontribusi positif area tersebut (Petsiuk et al., 2018).

Evaluasi *localization* mengukur kesesuaian spasial antara peta panas penjelasan dan *bounding box ground truth*. Metrik Pointing Game menghitung proporsi prediksi di mana titik dengan atribusi tertinggi pada peta panas jatuh di dalam *bounding box* objek sebenarnya yang didefinisikan pada Persamaan 2.28 (Zhang et al., 2018).

$$Acc_{PG} = \frac{Hits}{Hits + Misses} \quad (2.28)$$

Untuk evaluasi yang lebih ketat, IoU Heatmap menghitung *Intersection over Union* antara peta panas yang telah dibinerisasi (H_{bin}) dengan *bounding box ground truth* (B_{gt}) (Petsiuk et al., 2018) yang ditunjukkan pada Persamaan 2.29.

$$IoU_{Heatmap} = \frac{|H_{bin} \cap B_{gt}|}{|H_{bin} \cup B_{gt}|} \quad (2.29)$$

Nilai IoU Heatmap yang lebih tinggi menunjukkan tumpang tindih spasial yang lebih baik antara area yang disorot dan lokasi objek sebenarnya.

Evaluasi *explainability* yang komprehensif idealnya juga mencakup metrik *human-centered* seperti kepercayaan (*trust*), kepuasan (*satisfaction*), dan kemudahan pemahaman (*understandability*) yang diperoleh melalui studi dengan partisipan manusia (Hoffman et al., 2018). Namun, sesuai batasan penelitian, evaluasi dalam penelitian ini dibatasi pada metrik *functionally-grounded* yaitu *faithfulness* dan *localization* yang dapat diukur secara otomatis

2.2 Penelitian Terkait

Tabel 2.2 Ringkasan dan Perbandingan Penelitian Terkait

No.	Judul / Penulis	Masalah	Tujuan	Metode	Hasil	Keterkaitan
1.	<i>Improving PCB defect detection using selective feature attention and pixel shuffle pyramid (Fung et al., 2024)</i>	Deteksi cacat mikroskopis pada sirkuit PCB memiliki tingkat <i>false negative</i> yang tinggi pada model deteksi standar.	Meningkatkan kemampuan model melokalisasi target berukuran kecil pada citra PCB.	Faster R-CNN dengan <i>Feature Pyramid Network</i> (FPN), <i>Pixel Shuffle Pyramid</i> (PSPyramid), <i>Selective Feature Attention</i> , dan <i>Soft-NMS</i> .	Terjadi peningkatan <i>Mean Average Precision</i> (mAP) yang signifikan pada pengujian dataset DeepPCB.	Penelitian ini menjadi referensi utama arsitektur dasar (<i>baseline</i>) komponen Neuro (ekstraktor fitur dan lokalisasi) yang digunakan dalam tugas akhir ini.

2.	<i>Faster-LTN: a neuro-symbolic, end-to-end object detection architecture (Manigrasso et al., 2023)</i>	Model <i>deep learning</i> konvensional tidak mampu mengintegrasikan pengetahuan relasional dan penalaran logis ke dalam proses deteksi objek, sehingga kurang transparan dalam pengambilan keputusan.	Mengintegrasikan kemampuan penalaran logis dengan jaringan saraf konvolusional ke dalam arsitektur deteksi objek <i>end-to-end</i> untuk meningkatkan transparansi.	Faster R-CNN dengan penggantian kepala klasifikasi menjadi <i>Logic Tensor Networks</i> (LTN).	Arsitektur <i>end-to-end</i> berhasil dilatih dan mencapai performa kompetitif pada dataset PASCAL VOC.	Memberikan landasan konseptual integrasi pendekatan Neuro-Symbolic ke dalam arsitektur deteksi objek dua tahap (Faster R-CNN).
3.	<i>Sparse oblique decision trees: a tool to understand and manipulate neural net features (Hada et al., 2024)</i>	Lapisan MLP pada jaringan <i>deep learning</i> tidak dapat dijelaskan secara komputasional (<i>black-box</i>).	Menciptakan proyektor linear pengganti lapisan MLP tanpa menurunkan akurasi.	<i>Sparse Oblique Decision Tree</i> (SODT) dengan penerapan regularisasi L1.	Menghasilkan struktur pohon yang sangat ramping dengan performa setara MLP.	Menjadi landasan teoritis komponen Symbolic untuk

						menggantikan MLP pada <i>RoI head</i> jaringan Faster R-CNN.
4.	<i>Neurosymbolic models based on hybrids of convolutional neural networks and decision trees (Kairgeldin & Carreira-Perpiñán, 2025)</i>	Melatih struktur pohon secara global adalah masalah <i>NP-Hard</i> .	Mengoptimalkan bobot pohon secara efisien untuk data representasi dimensi tinggi.	<i>Algoritma iteratif Tree Alternating Optimization (TAO)</i> .	Pohon mencapai konvergensi lebih stabil dengan efisiensi komputasi tinggi.	Merupakan algoritma komputasi utama yang digunakan untuk proses <i>fitting</i> model SODT di penelitian ini.
5.	<i>Explainable Predictive Quality Inspection using Deep Learning in Electronics</i>	Model deep learning untuk prediksi kualitas bersifat <i>black-box</i> sehingga	Menyediakan penjelasan visual atas prediksi kualitas PCB menggunakan <i>heatmap</i> untuk membantu teknisi	<i>1D-CNN untuk prediksi kualitas biner (OK/NOK) dan Grad-CAM untuk menghasilkan</i>	Grad-CAM berhasil menyoroti fitur SPI (DX, DY, DVolume) dan	Menunjukkan aplikasi Grad-CAM sebagai metode <i>post-hoc</i> untuk

	<i>Manufacturing</i> (Saadallah et al., 2022)	menyulitkan teknisi memahami fitur mana yang paling berpengaruh terhadap keputusan prediksi.	mengidentifikasi fitur global (kuantitas fisik SPI) dan lokal (pin) yang paling menentukan.	<i>peta panas penjelasan.</i>	pin spesifik yang paling diskriminatif untuk kelas "NOK", membantu teknisi melacak penyebab deviasi kualitas.	inspeksi kualitas PCB,
6.	<i>Explainable AI Methods for Identification of Glue Volume Deficiencies in Printed Circuit Boards</i> (Tziolas et al., 2025)	Inspeksi volume lem pada PCB sulit dilakukan secara manual dan model <i>deep learning</i> yang digunakan tidak memberikan penjelasan atas deteksi defisiensi.	Mengidentifikasi defisiensi volume lem pada PCB menggunakan model <i>deep learning</i> dan menyediakan penjelasan visual atas prediksi model.	<i>CNN (ResNet-50 dan Vision Transformer) untuk klasifikasi defisiensi lem, dengan Grad-CAM dan Deep SHAP untuk menghasilkan peta panas penjelasan.</i>	CNN mencapai akurasi tinggi dalam mendeteksi defisiensi lem, dan Grad-CAM/Deep SHAP berhasil menyoroti area dengan volume	Memperkuat justifikasi penggunaan Grad-CAM sebagai metode <i>post-hoc</i> yang telah teruji dalam inspeksi visual PCB, serta

					lem tidak memadai yang menjadi dasar keputusan model.	menunjukkan keterbatasan <i>post-hoc</i> yang mendorong kebutuhan pendekatan <i>faithful</i> .
7.	<i>A study on the faithfulness of feature attribution explanations in pruned vision-based multi-task learning</i> (Arrighi et al., 2023)	Metode atribusi fitur <i>post-hoc</i> seringkali tidak <i>faithful</i> , yaitu tidak merepresentasikan secara akurat proses pengambilan keputusan model yang sesungguhnya.	Mengevaluasi <i>faithfulness</i> dari berbagai metode atribusi fitur pada model <i>multi-task learning</i> yang telah dipangkas (<i>pruned</i>).	Analisis komparatif kuantitatif <i>faithfulness</i> menggunakan metrik <i>Deletion AUC</i> dan <i>Insertion AUC</i> pada beberapa metode atribusi	<i>Faithfulness</i> metode atribusi menurut signifikan pada model yang telah dipangkas dan tidak ada metode tunggal yang unggul di semua skenario. Grad-CAM menunjukkan	Memberikan landasan teoritis dan empiris bahwa metode <i>post-hoc</i> seperti Grad-CAM memiliki keterbatasan <i>faithfulness</i> sehingga mendukung


					<i>faithfulness</i> yang moderat tetapi tidak optimal	urgensi pendekatan <i>neuro- synmbolic</i> yang menjamin <i>faithfulness</i>
--	--	--	--	--	--	---

BAB III

METODOLOGI PENELITIAN

Penelitian ini dilaksanakan melalui tahapan-tahapan sistematis guna membangun, mengintegrasikan, dan mengevaluasi sistem deteksi cacat Printed Circuit Board (PCB) berbasis arsitektur hibrida neuro-simbolik. Penjabaran metodologi secara komprehensif pada bagian ini mencakup proses persiapan dataset industri, pra-pemrosesan citra komputasional, rekayasa model ekstraktor fitur koneksionis (Faster R-CNN), hingga pelatihan dan integrasi komponen pengambil keputusan simbolik (Sparse Oblique Decision Tree - SODT) yang *explainable*.

Secara garis besar, keseluruhan alur kerja (*workflow*) dari tahap awal hingga evaluasi akhir direpresentasikan melalui diagram alur penelitian berikut:



Gambar 3.1 Diagram Alur Penelitian

3.1 Persiapan Dataset

Penelitian ini menggunakan dataset citra publik DeepPCB. Alur penyiapan data dirancang agar efisien secara memori dan terisolasi secara ketat untuk mencegah bias pelatihan. Tahapan persiapan ini mencakup proses berikut:

1. Pemisahan Data Terisolasi (*Train/Test Split*)

Proses diawali dengan membaca berkas indeks bawaan dataset. Berkas *trainval.txt* dialokasikan secara eksklusif untuk fase pelatihan (*training*) tanpa pemisahan data validasi tambahan. Sementara itu, berkas *test.txt* dikunci untuk pengujian akhir. Pemisahan sejak level pembacaan indeks ini wajib dilakukan

guna mencegah kebocoran data (*data leakage*) dan menjaga keaslian objektivitas evaluasi akhir model. Detail dari pembagian dipetakan sebagai berikut:

Tabel 3.1 Pembagian dataset berdasarkan kategori


Kategori	Berkas Indeks	Jumlah Citra	Persentasi (%)
Data Pelatihan (Training)	<i>trainval.txt</i>	1.000	66,67%
Data Pengujian (Testing)	<i>test.txt</i>	500	33,33%

2. Pemindaian Direktori Mode *Non-Referential*

Berdasarkan *path* yang termuat dalam berkas indeks, algoritma *data loader* melakukan pemindaian direktori secara rekursif, menyusuri struktur folder *groupXXXXX/* hingga sub-direktori **_not/*. Sistem deteksi ini dibangun menggunakan pendekatan *non-referential*, yang berarti algoritma secara sengaja mengabaikan gambar referensi papan sehat (*_temp.jpg*) dan hanya memuat citra target bersufiks *_test.jpg*. Pendekatan ini ditujukan agar model mampu melakukan deteksi cacat secara mandiri (*blind detection*) tanpa bergantung pada perbandingan citra *template*.

3. Ekstraksi Anotasi *On-The-Fly*

Bersamaan dengan pemuatan citra ke dalam *DataLoader*, label anomali diekstrak secara dinamis saat proses inferensi berjalan (*on-the-fly*). Algoritma mengurai setiap baris pada berkas anotasi .txt untuk memperoleh koordinat *bounding box* aktual (*ground truth*) beserta label kelasnya. Teks kelas anomali tersebut langsung dipetakan secara statis ke dalam enam kategori: *open*, *short*, *mouse_bite*, *spur*, *pinhole*, dan *spurious_copper* dengan contohnya pada Gambar 3.2.



Gambar 3.2 Contoh sampel dataset PCB beserta anotasinya

4. Konversi dan *Casting* Tensor

Hasil ekstraksi secara langsung dikonversi (*cast*) menjadi struktur tensor PyTorch. Matriks koordinat *bounding box* disimpan dengan presisi float32 untuk mengakomodasi perhitungan *loss* regresi secara akurat. Sementara itu, nama kelas anomali dikonversi menjadi indeks numerik bertipe int64 yang diwajibkan untuk perhitungan *loss* klasifikasi kelas.

3.2 Preprocessing Gambar

Setelah citra dimuat oleh *DataLoader*, sistem melakukan serangkaian transformasi digital guna memastikan data siap diproses oleh jaringan saraf. Tahapan ini dibagi menjadi dua fokus utama, yaitu standardisasi nilai piksel dan augmentasi citra.

Proses standarisasi piksel bertujuan untuk menyelaraskan distribusi statistik masukan citra PCB dengan bobot prapelatihan (*pre-trained*) pada *backbone* ResNet-50 yang dilatih menggunakan dataset ImageNet. Dengan penyelarasan ini, model tidak perlu belajar dari nol untuk mengenali fitur dasar (tepi dan tekstur), sehingga konvergensi saat pelatihan berlangsung jauh lebih cepat dan stabil. Detail nilai standardisasi dijabarkan pada Tabel 3.2.

Tabel 3.2 Parameter Normalisasi dan Standardisasi Input

Parameter	Nilai Konfigurasi	Tujuan
Rentang Intensitas	[0.0, 1.0]	Penyeragaman <i>dynamic range</i> piksel
Rata-rata (<i>Mean</i>)	[0.485, 0.456, 0.406]	Penyelarasan distribusi ImageNet
Deviasi Standar (<i>Std</i>)	[0.229, 0.224, 0.225]	Penyelarasan distribusi ImageNet

Setelah standarisasi piksel, sistem akan menerapkan augmentasi pada fase pelatihan guna meningkatkan ketahanan model terhadap variasi visual di lapangan. Strategi ini dirancang untuk memperkaya orientasi spasial dan memperkuat invariansi skala tanpa mengubah makna semantik dari jenis cacat yang dideteksi. Augmentasi dilakukan secara sinkron antara citra dan koordinat *bounding box* untuk menjaga presisi anotasi meskipun citra mengalami transformasi. Rincian konfigurasi augmentasi yang diterapkan dijabarkan pada Tabel 3.3.

Tabel 3. 3 Konfigurasi Augmentasi Data Pelatihan

Jenis Augmentasi	Parameter	Dekripsi
<i>Random Horizontal Flip</i>	Probabilitas: 0,5	Pembalikan gambar secara horizontal untuk variasi arah
<i>Multi-resolution Scaling</i>	Sisi Terpendek: {480, 560, 640, 720, 800, 880}	Pemilihan resolusi secara acak untuk ketahanan skala
<i>Coordinate Sync</i>	Enabled	Penyesuaian otomatis lokasi <i>box</i> saat gambar berubah

3.3 Model Neuro (*Faster R-CNN*)

Model koneksionis dalam penelitian ini menggunakan arsitektur Faster R-CNN yang berperan sebagai *teacher* sekaligus ekstraktor fitur utama. Konfigurasi model

secara spesifik mengacu pada reproduksi arsitektur Fung et al. (2024) yang telah terbukti optimal untuk mendeteksi anomali berukuran mikro pada permukaan PCB. Guna memudahkan proses replikasi, keseluruhan parameter operasional dan konfigurasi teknis dari arsitektur ini dikonsolidasikan secara lengkap pada Tabel 3.4.

Tabel 3.4 Parameter utama Faster R-CNN

Modul Fungsional	Parameter Utama	Nilai / Konfigurasi
<i>Backbone & Neck</i>	Inisialisasi Bobot	Pra-pelatihan ImageNet (<i>Pre-trained</i>)
	Batch Normalization	Dibekukan (<i>freeze_batch_norm: true</i>)
	Peta Fitur FPN	p2, p3, p4, p5, p6
	Reduksi Atensi	16
<i>Region Proposal (RPN)</i>	Ukuran Jangkar (<i>Anchor Sizes</i>)	[16, 32, 64, 128, 256] piksel
	Rasio Aspek	[0.5, 1.0, 2.0]
	Ambang Batas IoU	<i>Foreground: 0.7</i> <i>Background: 0.3</i>
	Batas Proposal Kandidat	<i>Train: 2000</i> <i>Test: 1000</i> (<i>Pre/Post-NMS</i>)
<i>RoI Head</i>	Dimensi <i>RoI Align</i>	<i>7x7 piksel (Rasio sampling: 2)</i>
	Ukuran Representasi	<i>1024 dimensi</i>
<i>Soft-NMS</i>	Metode Penurunan (<i>Decay</i>)	<i>Linier (Linear)</i>
	Parameter Sigma & IoU	<i>Sigma: 0.5</i> <i>IoU Threshold: 0.5</i>
	Pemotongan Skor (<i>Score Thresh</i>)	<i>0.001</i>

Secara fungsional, arsitektur yang dijabarkan pada tabel di atas bekerja melalui alur sekuensial yang terbagi ke dalam empat tahap pemrosesan utama.

Tahap pertama bertumpu pada modul Backbone dan Neck yang bertugas sebagai pengekstraksi fitur dasar. Modul ini dibangun di atas *backbone* ResNet-50. Selama proses pelatihan berlangsung, seluruh lapisan *Batch Normalization* sengaja dibekukan guna menjaga kestabilan gradien, mengingat pelatihan model *object detection* umumnya terkendala oleh kapasitas ukuran *batch* yang terbatas di VRAM. Fitur spasial yang dihasilkan kemudian diperkuat pada bagian *neck* menggunakan *Feature Pyramid Network* (FPN) yang diintegrasikan dengan modul atensi untuk meredam derau visual (*noise*) latar belakang sirkuit yang tidak relevan.

Selanjutnya, peta fitur tersebut diproses oleh *Region Proposal Network* (RPN) untuk menghasilkan area kandidat objek secara ekstensif. RPN memanfaatkan variasi lima ukuran jangkar (*anchor*) dasar dan tiga rasio aspek untuk memastikan cacat dengan bentuk ekstrem sekalipun dapat terdeteksi. Klasifikasi awal untuk menentukan apakah sebuah area merupakan target (*foreground*) atau sekadar latar (*background*) ditentukan melalui ambang batas *Intersection over Union* (IoU) secara ketat. Demi menjaga efisiensi komputasi tanpa mengorbankan potensi deteksi, jumlah kandidat proposal yang diteruskan sistem dibatasi maksimal 2000 kandidat pada fase pelatihan, dan direduksi menjadi 1000 kandidat saat fase pengujian.

Kandidat area yang lolos dari RPN kemudian memasuki tahap pelokalan di modul RoI Head dan Klasifikasi Dasar. Setiap area proposal diproyeksikan menggunakan operasi *RoI Align* untuk memproyeksikan area proposal secara presisi menjadi matriks spasial berdimensi tetap 7x7 piksel dengan rasio *sampling* sebesar 2. Matriks fitur tersebut lalu dipipihkan (*flattened*) menjadi vektor representasi linear berdimensi 1024. Sebagai mekanisme klasifikasi dasar (sebelum nantinya digantikan oleh struktur pohon simbolik), vektor representasi ini dilewatkan pada lapisan *Multi-Layer Perceptron* (MLP) *black-box* bawaan model untuk memprediksi probabilitas kelas cacat.

Tahapan terakhir dari alur arsitektur ini adalah pascapemrosesan menggunakan Soft-NMS. Pada kasus inspeksi PCB, letak antar-cacat sering kali sangat

berdekatan atau bahkan saling tumpang tindih (misalnya cacat *spur* yang menempel di dekat jalur *short*). Jika menggunakan algoritma NMS konvensional, kandidat *bounding box* yang saling tumpang tindih tersebut akan dieliminasi secara paksa. Oleh karena itu, sistem ini mengimplementasikan *Soft-NMS* dengan metode penurunan skor secara linier. Melalui metode ini, skor kandidat yang berdekatan tidak dipotong habis melainkan hanya ditekan sebagian secara proporsional. Pendekatan ini memungkinkan model untuk mempertahankan identifikasi objek anomali yang lokasinya saling berdekatan dengan akurasi yang lebih konsisten.

3.4 Pelatihan dan Evaluasi Model Neuro

Fase ini dirancang untuk melatih arsitektur Faster R-CNN sekaligus memvalidasi keandalannya sebagai model Teacher sebelum representasi fiturnya diekspor ke komponen simbolik. Mengingat model koneksionis ini akan menjadi fondasi representasi pengetahuan utama, proses pelatihan harus dilakukan secara optimal dan evaluasi kinerja pelokalan diukur secara ketat guna mencegah propagasi kesalahan (*error propagation*) ke modul pohon keputusan (SODT) pada tahap berikutnya.

Proses pelatihan dirancang untuk berjalan selama 12 *epoch* penuh. Guna mengatasi keterbatasan kapasitas memori GPU (*VRAM*), skema pelatihan mengimplementasikan teknik *Automatic Mixed Precision* (AMP) dan *Gradient Accumulation*. Dengan *batch size* dasar sebesar 1 dan akumulasi gradien sebanyak 4 langkah, sistem dapat menyimulasikan *batch size* efektif sebesar 4 tanpa menyebabkan *Out of Memory*.

Optimasi bobot jaringan akan dilakukan menggunakan fungsi pengoptimal yang mengandalkan momentum dengan skema *learning rate* yang dinamis. Pada awal pelatihan, diterapkan mekanisme pemanasan (*Warmup*) linier untuk mencegah lompatan gradien yang ekstrem. Setelah fase pemanasan, laju pembelajaran akan diturunkan secara berkala mengikuti pengaturan pencapaian target (*Milestone Scheduler*). Spesifikasi lengkap mengenai rancangan parameter pelatihan model *neuro* ini dikonsolidasikan pada Tabel 3.5.

Tabel 3. 5 Hyperparameter pelatihan model Faster R-CNN

<i>Hyperparameter</i>	Parameter Utama	Nilai / Konfigurasi
Siklus Pelatihan	Total <i>Epoch</i>	12
	Gradient Accumulation	4 langkah (<i>Effective Batch</i> : 4)
	Presisi Komputasi	<i>Automatic Mixed Precision</i> (<i>AMP</i> : <i>True</i>)
Fungsi Pengoptimal	Optimizer	SGD
	Laju Pembelajaran (<i>Learning Rate</i>)	0,02
	Momentum & <i>Weight Decay</i>	Momentum: 0.9 <i>Decay</i> : 0.0001
Penjadwalan (Scheduler)	Tipe <i>Scheduler</i>	Milestone / Step Decay
	Pencapaian (<i>Milestones</i>)	<i>Epoch</i> ke-8 dan ke-11
	Faktor Penurunan (<i>Gamma</i>)	0.1 (Penurunan 10%)
Pemanasan (Warmup)	Iterasi <i>Warmup</i>	500 langkah
	Rasio <i>Warmup</i> Awal	0.001


Setelah proses iterasi pelatihan selesai, model akan dievaluasi secara komprehensif menggunakan data pengujian yang terisolasi di dalam berkas *test.txt*. Sistem akan melakukan inferensi terhadap citra uji dan membandingkan *bounding box* hasil prediksi beserta probabilitas kelasnya dengan anotasi *ground truth*.

Kinerja pelokalan dan klasifikasi diukur menggunakan *Intersection over Union* (IoU) sebagai dasar penentuan *True Positive* pada setiap kelas cacat. Berbeda dengan evaluasi sederhana, pengujian ini dirancang untuk menghitung presisi rata-rata pada berbagai tingkat ambang batas ketat, yaitu rentang IoU dari 0.50 hingga

0.85 dengan interval 0.05. Hasil pengujian dari berbagai tingkat ambang batas dan kelas tersebut kemudian diakumulasikan ke dalam metrik *Mean Average Precision* (mAP). Target dari evaluasi ini adalah untuk memastikan bahwa ekstraktor fitur koneksionis memiliki akurasi deteksi dan tingkat kebingungan kelas (*class confusion*) yang minim sebelum seluruh bobot model dibekukan (*frozen*) untuk keperluan fase ekspor simbolik

3.5 Ekstraksi Fitur RoI dan Hasil Klasifikasi *Faster R-CNN*

Setelah model *Teacher* (*Faster R-CNN*) dievaluasi dan bobot parameternya dibekukan (*frozen*), alur penelitian bergeser dari tugas deteksi objek menuju ekstraksi representasi fitur. Tujuan utama fase ini adalah menyusun dataset sekunder (turunan) yang akan digunakan sebagai basis pelatihan model simbolik. Tahapan ekstraksi ini tidak dilakukan secara *end-to-end* dalam satu waktu pelatihan, melainkan dipecah melalui tiga mekanisme prosedural berdasarkan gambar berikut:



Gambar 3.3 Pengambilan RoI Align dan Hasil dari *Faster R-CNN*

1. Modifikasi Alur Inferensi (*Feature Hooking*)

Arsitektur *Faster R-CNN* dimodifikasi agar inferensi tidak hanya menghasilkan prediksi akhir, melainkan juga mengambil fitur secara langsung dari luaran operasi *RoI Align* (*box_roi_pool*). Pendekatan ini menangkap fitur dalam bentuk tensor spasial berdimensi tetap 7×7 sebelum direduksi menjadi vektor 1024 dimensi oleh lapisan MLP.

2. Eksekusi Pemindaian Luring (*Offline Export*)

Model *Teacher* yang telah dimodifikasi menjalankan inferensi secara luring terhadap seluruh data latih. Setiap kandidat bounding box yang dihasilkan RPN dipetakan menjadi kumpulan *tensor* fitur spasial. Eksekusi ini memisahkan beban komputasi antara pelatihan komponen *neuro* dan optimasi komponen *simbolik*.

3. Penyusunan Dataset Simbolik

Seluruh hasil ekstraksi diakumulasikan ke dalam struktur data persisten. Dataset sekunder ini memuat tensor fitur spasial 7×7 , koordinat bounding box, skor kepercayaan deteksi, serta label kelas hasil prediksi model *Teacher* yang berfungsi sebagai *teacher labels*. Dataset inilah yang menjadi dasar pelatihan lapisan simbolik selanjutnya.

3.6 Model Simbolik (SODT)

Berdasarkan *dataset* sekunder berformat persisten yang telah diekspor, penelitian ini mengimplementasikan *Sparse Oblique Decision Tree* (SODT) yang mengacu pada formulasi Hada et al. (2024). SODT dikonstruksikan sebagai komponen pengambil keputusan simbolik utama guna menggantikan lapisan klasifikasi *black-box*, yaitu *Multi-Layer Perceptron* pada arsitektur Faster R-CNN. Proses konstruksi arsitektur simbolik ini secara khusus dirancang untuk memastikan transparansi keputusan (*faithfulness*) melalui karakteristik struktural berikut:

1. Penapisan Dinamis (*Feature Screening*)

Sebelum pembentukan simpul dimulai, tensor fitur spasial (hasil keluaran *RoI Align* berdimensi 1024) yang diekstrak akan melewati fase penapisan. Melalui ambang batas aktivasi ($1e-8$) dan variansi ($1e-5$), sistem secara dinamis mengeleminasi dimensi fitur yang selalu bernilai nol, berfluktuasi sangat rendah (pasif), atau tidak merepresentasikan informasi visual yang bermakna. Langkah *screening* ini mereduksi kerumitan pencarian sehingga pohon yang dibangun terhindar dari *overfitting* terhadap artefak latar belakang sirkuit.

2. Pemodelan *Oblique Splits*

Setiap simpul keputusan internal menggunakan proyektor multivariat yang mengevaluasi pertidaksamaan linear 2.19. Pendekatan ini memungkinkan partisi

ruang fitur secara miring, tidak terbatas pada pemisahan ortogonal seperti pohon konvensional.

3. Penerapan Regularisasi *Sparsity*

Untuk menjaga interpretabilitas tinggi, pembelajaran parameter w diregularisasi menggunakan penalti norma-L1. Mekanisme ini memaksa bobot pada dimensi fitur yang tidak relevan menjadi nol, sehingga setiap jalur keputusan dari akar ke daun hanya bergantung pada subset fitur visual yang benar-benar berpengaruh terhadap penentuan kelas cacat.

3.7 Pelatihan dan Evaluasi Model Simbolik

Tahap selanjutnya adalah melakukan pelatihan terhadap arsitektur SODT. Berbeda dengan model *deep learning* yang umumnya dilatih menggunakan satu penetapan *hyperparameter* yang kaku, pelatihan model simbolik ini dirancang untuk melakukan pencarian model terbaik melalui metode *Regularization Path* (pencarian jalur regularisasi). Tujuannya adalah menemukan satu pohon kandidat yang memiliki ukuran paling ringkas namun tetap mampu menyamai atau meniru akurasi dari model *Teacher*. Rincian parameter pelatihan dan pemilihan pohon dirangkum pada Tabel 3.6.

Tabel 3.6 Hyperparameter pelatihan SODT

Tahapan/Komponen	Parameter Utama	Nilai / Deskripsi Operasional
Struktur <i>Grid Search</i>	Variasi Kedalaman Pohon (<i>Depth</i>)	{2, 3, 4} (Pencarian kombinasi)
	Target Kelas	6 kelas (beserta <i>background</i>)
	Iterasi Global TAO	20 iterasi
Regularisasi <i>Grid Search</i>	Variasi Penalti L1 (λ)	{1.0, 3.0, 10.0, 30.0}
	Kombinasi Sparsitas (α)	{0.0, 0.5, 1.0}
Optimasi <i>Tree Alternating</i> (TAO)	Iterasi Global TAO	20 iterasi
	Maksimal Iterasi Logistik	100 langkah per <i>node fit</i>
Kriteria Seleksi (<i>Tolerances</i>)	Batas Penurunan <i>Mimic Accuracy</i>	Maksimal 0.005 (0.5%) dari <i>Teacher</i>
	Batas Penurunan <i>Macro F1</i>	Maksimal 0.005 (0.5%) dari <i>Teacher</i>
	Ambang Batas Minimal Akurasi	Minimal 0.98 (98%)

Proses pencarian dan optimasi kandidat model dieksekusi melalui tahapan komputasi berikut:

1. Optimasi Iteratif menggunakan Algoritma *Tree Alternating Optimization* (TAO)

TAO memperbarui simpul-simpul keputusan pada kedalaman yang sama secara serentak menggunakan solver LIBLINEAR Logistic Regression, kemudian mengulangi siklus tersebut secara bergantian hingga batas iterasi global yang telah didefinisikan pada Tabel 3.6 tercapai atau konvergensi terbentuk.

2. Eksekusi Pencarian Jalur Regularisasi (*Grid Search*)

Sistem menjalankan algoritma TAO secara iteratif pada seluruh kombinasi parameter yang telah ditetapkan. Setiap kombinasi kedalaman pohon (2, 3, 4), nilai penalti L1 (1.0, 3.0, 10.0, 30.0), dan faktor sparsitas α (0.0, 0.5, 1.0) akan dilatih secara independen. Berdasarkan permutasi tersebut, sistem akan membangkitkan puluhan spesimen pohon kandidat yang memiliki variasi tingkat akurasi dan tingkat kerumitan penggunaan fitur yang berbeda-beda.

3. Evaluasi Ambang Batas Keselarasan (*Faithful Tolerance*)


Seluruh pohon kandidat yang telah dilatih kemudian dievaluasi menggunakan metrik *Mimic Accuracy* dan *Macro F1*. Evaluasi ini mengukur seberapa persis identitas tebakan komponen simbolik dengan label keluaran model *Teacher*. Pohon kandidat yang mengalami penurunan performa (selisih ketepatan) lebih dari 0.005 dibandingkan akurasi *Teacher* murni, atau gagal menembus batas akurasi minimal absolut sebesar 0.98, akan langsung dieliminasi dari daftar pemilihan.

4. Seleksi Kandidat Terekstrem (*Sparsest Selection*)

Dari sisa kumpulan kandidat yang berhasil melewati ambang batas keselarasan performa, sistem menerapkan kebijakan seleksi tingkat akhir. Model yang ditetapkan untuk diekspor ke tahap integrasi final adalah model yang memiliki jumlah fitur aktif (*nonzero weights*) paling sedikit dan rata-rata penggunaan fitur per simpul terendah. Mekanisme seleksi berjenjang ini menjamin bahwa model *neuro-symbolic* akhir merupakan representasi teringan dan paling transparan secara logika tanpa mengorbankan utilitas deteksi.

3.8 Integrasi *Faster R-CNN* dan SODT

Tahap ini menyatukan ekstraktor fitur neuro dengan pengambil keputusan simbolik menjadi satu alur inferensi hibrida yang *end-to-end*. Proses integrasi dan mekanisme *explainability* dilaksanakan melalui empat langkah prosedural yang divisualisasikan Gambar 3.4.



Gambar 3.4 Diagram integrasi *Neuro-Symbolic*

1. Substitusi Modul Klasifikasi

Lapisan klasifikasi MLP bawaan Faster R-CNN dinonaktifkan sepenuhnya. Representasi fitur laten hasil RoI Align (vektor 1024 dimensi) dialihkan langsung menjadi masukan bagi model SODT yang telah dikalibrasi sebelumnya.

2. Inferensi Hibrida Sekuensial

Alur deteksi berjalan sekuensial dengan arsitektur *neuro* bertugas sebagai pengusul area dan ekstraktor fitur visual. Setiap kandidat *bounding box* yang lolos evaluasi *Soft NMS* selanjutnya diklasifikasikan oleh SODT, dan label akhir ditentukan berdasarkan simpul daun yang dicapai fitur tersebut pada struktur pohon.

3. Rekonstruksi Bobot Jalur

Untuk menghasilkan representasi visual dari keputusan model, algoritma menelusuri jalur keputusan dari akar hingga daun target. Bobot *sparse* dari simpul-simpul internal di sepanjang jalur tersebut diakumulasikan secara linear, menghasilkan satu vektor bobot agregat yang menunjukkan signifikansi tiap elemen fitur terhadap keputusan akhir.

4. Proyeksi *Heatmap* (*Density Map*)

Vektor *weight* agregat berdimensi 1024 dilipat kembali menjadi matriks spasial 7×7 , kemudian diskalakan ke atas (*upscaled*) menggunakan interpolasi agar sesuai dengan ukuran piksel *bounding box* target. Peta spasial tersebut dilapiskan di atas gambar asli dalam bentuk *heatmap* untuk menyoroti area *piksel* yang memicu keputusan klasifikasi SODT.

3.9 Evaluasi Model *Neuro-Symbolic*

Tahap akhir metodologi difokuskan pada pengujian komprehensif sistem hibrida *neuro-symbolic* yang telah terintegrasi penuh. Evaluasi dilakukan secara terisolasi terhadap himpunan data uji dalam berkas *test.txt*. Berdasarkan landasan teori metrik evaluasi yang telah ditetapkan, pengujian ini dieksekusi melalui tiga skema parameter utama:

1. Evaluasi Kinerja Kuantitatif (Komparasi mAP)

Sistem menjalankan inferensi penuh pada data uji untuk memprediksi kelas cacat dan koordinat letaknya. Kinerja pelokalan dan klasifikasi diukur menggunakan *Intersection over Union* (IoU) yang kemudian diakumulasikan menjadi metrik *Mean Average Precision* (mAP) untuk keenam kelas anomali. Tujuan utama dari evaluasi ini bukan sekadar mencari nilai tertinggi, melainkan untuk membandingkan langsung mAP dari model hibrida neuro-simbolik (Faster R-CNN + SODT) dengan mAP *baseline* dari model *Teacher* (Faster R-CNN + MLP murni). Komparasi ini difungsikan untuk mengukur *performance gap* atau toleransi penurunan presisi yang terjadi akibat penggantian lapisan *black-box* dengan struktur pohon keputusan proyekatif.

2. Evaluasi *Explainability* Kuantitatif (*Faithfulness* dan *Localization*)

Sesuai dengan batasan penelitian yang difokuskan pada evaluasi berbasis sistem (*functionally-grounded*), kualitas transparansi (*explainability*) dari peta panas yang dihasilkan oleh SODT diukur secara kuantitatif melalui dua dimensi:

a. *Faithfulness* (Kejujuran Model)

Dievaluasi menggunakan metrik *Deletion AUC* dan *Insertion AUC*. Secara operasional, sistem akan memodifikasi area piksel citra uji secara bertahap (dihapus atau disisipkan) berdasarkan urutan prioritas intensitas sorotan pada peta panas SODT. Penurunan skor prediksi yang drastis saat area penting

dihapus (*Deletion*), dan pemulihan skor yang cepat saat area penting disisipkan (*Insertion*), akan mengonfirmasi bahwa peta panas tersebut jujur dan merepresentasikan parameter logis yang sesungguhnya dipakai oleh pohon keputusan.

b. *Localization* (Kesesuaian Spasial)

Dievaluasi menggunakan metrik *Pointing Game* dan *IoU Heatmap*. Sistem mengeksekusi *script* untuk memvalidasi apakah titik piksel dengan atribusi bobot tertinggi pada peta panas jatuh tepat di dalam *bounding box ground truth* (objek cacat sebenarnya). Selanjutnya, luasan peta panas akan dibinerisasi untuk dihitung rasio tumpang tindihnya terhadap *bounding box* aktual guna memastikan kebenaran semantik visualnya.

3. Evaluasi *Explainability* Kualitatif (Komparasi Visual XAI)

Sebagai bentuk validasi pelengkap, evaluasi kualitatif dilakukan melalui inspeksi visual langsung terhadap *heatmap* yang dihasilkan pada sampel prediksi, baik untuk kasus *True Positive* maupun *False Positive*. Pada tahap ini, peta panas proyektif dari luaran SODT—yang diklaim transparan secara arsitektur (*faithful by design*)—akan disandingkan dan dibandingkan langsung dengan peta panas yang dihasilkan oleh metode eksplanasi konvensional (*post-hoc*), yaitu Grad-CAM (yang diekstrak dari peta fitur model *Teacher*). Komparasi visual ini ditujukan untuk membuktikan hipotesis bahwa agregasi bobot dari SODT mampu menyorot lokasi fisik anomali PCB dengan lebih tajam, logis, dan minim gangguan artefak latar belakang (*noise*) dibandingkan dengan sekadar estimasi gradien propagasi-mundur milik Grad-CAM.

DAFTAR PUSTAKA

- Ali, A.M.M., Ziyi, X., Sahlan, S., Khamis, N., Nor Rashid, F.'A., 2023. Transparency in Detecting Defects of a Printed Circuit Board: Harnessing XAI for Improved Quality Control in Electronic Manufacturing. In: 2023 IEEE 9th International Conference on Smart Instrumentation, Measurement and Applications (ICSIMA), pp. 1-6.
- Arrighi, L., Pintus, F., Giuliani, L., Vantini, S., & Bacciu, D., 2023. A study on the faithfulness of feature attribution explanations in pruned vision-based multi-task learning. *CEUR Workshop Proceedings*, 4017.
- Carreira Perpiñán, M.Á., Tavallali, P., 2018. Alternating optimization of decision trees, with application to learning sparse oblique trees. In: *Advances in Neural Information Processing Systems (NeurIPS)*, 31, pp. 1211–1221.
- Canha, D., Kubler, S., Främling, K., & Fagherazzi, G. (2025). A Functionally-Grounded Benchmark Framework for XAI Methods: Insights and Foundations from a Systematic Literature Review. *ACM Computing Surveys*, *57*(12), Article 320.
- Chen, X., Wu, Y., He, X., Ming, W., 2023. A Comprehensive Review of Deep Learning-Based PCB Defect Detection. *IEEE Access* 11, 139017-139036.
- Coombs, C.F., Holden, H.T., 2016. *Printed Circuits Handbook*, 7th ed. McGraw-Hill Education, New York.
- d'Avila Garcez, A. and Lamb, L.C., 2023. Neurosymbolic AI: the 3rd wave. *Artificial Intelligence Review*, 56(11), pp.12387-12406.
- Fung, K.C., Xue, K.-W., Lai, C.-M., Lin, K.-H., Lam, K.-M., 2024. Improving PCB defect detection using selective feature attention and pixel shuffle pyramid. *Results in Engineering* 21, 101992.
- Girshick, R. (2015). Fast R-CNN. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 1440-1448). IEEE.
- Goodfellow, I., Bengio, Y., Courville, A., 2016. *Deep Learning*. MIT Press, Cambridge, MA.

- Hada, S.S., Carreira-Perpiñán, M.Á. and Zharmagambetov, A., 2024. Sparse oblique decision trees: a tool to understand and manipulate neural net features. *Data Mining and Knowledge Discovery*, 38(5), pp.2863-2902.
- Han, Z., Hong, M., Wang, D., 2017. Deep learning and applications. In: *Signal Processing and Networking for Big Data Applications*. Cambridge University Press, Cambridge, pp. 203-228.
- IPC, 2020. *IPC-A-600K: Acceptability of Printed Boards*. Association Connecting Electronics Industries.
- Kairgeldin, R. and Carreira-Perpiñán, M.Á., 2025. Neurosymbolic models based on hybrids of convolutional neural networks and decision trees. *Proceedings of Machine Learning Research (NeSy 2025)*, 284, pp.796-813.
- Khandpur, R.S., 2005. *Printed Circuit Boards: Design, Fabrication, and Assembly*. McGraw-Hill Education.
- Klette, R., 2014. *Concise Computer Vision: An Introduction into Theory and Algorithms*. Springer, London.
- LeCun, Y., Bengio, Y., Hinton, G., 2015. Deep learning. *Nature*, 521(7553), pp. 436-444.
- Manigrasso, F., Miro, F.D., Morra, L. and Lamberti, F., 2021. Faster-LTN: a neuro-symbolic, end-to-end object detection architecture. In: *International Conference on Artificial Neural Networks (ICANN)*. Springer, pp.40-52.
- Minaee, S., Boykov, Y., Porikli, F., Plaza, A., Kehtarnavaz, N., Terzopoulos, D., 2021. Image segmentation using deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(7), pp.3523-3542.
- Petsiuk, V., Das, A., & Saenko, K. (2018). RISE: Randomized Input Sampling for Explanation of Black-box Models. In *Proceedings of the British Machine Vision Conference (BMVC)* (pp. 1-13). BMVA Press.
- Prince, S. J. D. (2023). *Understanding Deep Learning*. The MIT Press

- Rudin, C., 2019. Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), pp.206-215.
- Saadallah, A., Büscher, J., Abdulaaty, O., Panusch, T., Deuse, J., Morik, K., 2022. Explainable Predictive Quality Inspection using Deep Learning in Electronics Manufacturing. *Procedia CIRP* 107, 594-599.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual Explanations From Deep Networks via Gradient-Based Localization. In *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618-626). IEEE.
- Shi, W., Caballero, J., Huszár, F., Totz, J., Aitken, A. P., Bishop, R., ... & Wang, Z. (2016). Real-Time Single Image and Video Super-Resolution Using an Efficient Sub-Pixel Convolutional Neural Network. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 1874-1883). IEEE
- Szeliski, R., 2022. *Computer Vision: Algorithms and Applications*, 2nd ed. Springer, Cham.
- Tziolas, T., Papageorgiou, K., Theodosiou, T., Ioannidis, D., Dimitriou, N., Tinker, G., Papageorgiou, E., 2025. Explainable AI Methods for Identification of Glue Volume Deficiencies in Printed Circuit Boards. *Applied Sciences* 15(16), 9061.
- Tzionis, G., Mouratidis, P., Kougka, G., Gialampoukidis, I., Vrochidis, S., Kompatsiaris, I., Vlachopoulou, M., 2026. A review of explainable AI methods and their application in manufacturing systems. *Discover Applied Sciences* 8, 52.
- Wang, Y., Huang, J., Dipu, M.S.K., Zhao, H., Gao, S., Zhang, H., Lv, P., 2024. YOLO-RLC: An Advanced Target-Detection Algorithm for Surface Defects of Printed Circuit Boards Based on YOLOv5. *Computers, Materials & Continua* 80(3), 4973-4995.

Zhao, X., Wang, L., Zhang, Y., Han, X., Deveci, M., Parmar, M., 2024. A review of convolutional neural networks in computer vision. *Artificial Intelligence Review* 57(4), 99.

DETEKSI CACAT PCB DENGAN PENJELASAN YANG FAITHFUL MELALUI ARSITEKTUR NEURO-SYMBOLIC FASTER R-CNN DAN SPARSE OBLIQUE DECISION TREE

ORIGINALITY REPORT

8%	7%	3%	3%
SIMILARITY INDEX	INTERNET SOURCES	PUBLICATIONS	STUDENT PAPERS

PRIMARY SOURCES

1	if.mipa.uns.ac.id Internet Source	<1 %
2	Submitted to Perpustakaan Student Paper	<1 %
3	docplayer.info Internet Source	<1 %
4	kc.umn.ac.id Internet Source	<1 %
5	Submitted to Universitas Gunadarma Student Paper	<1 %
6	link.springer.com Internet Source	<1 %
7	Submitted to UPN Veteran Yogyakarta Student Paper	<1 %
8	Submitted to Universitas Negeri Jakarta Student Paper	<1 %
9	pmc.ncbi.nlm.nih.gov Internet Source	<1 %
10	Abdurroziq, Ali. "Analisis Model Inquiry Based Learning (IBL) Dalam Pembelajaran Rumpun Pendidikan Agama Islam (PAI) di ma Minat	<1 %

Kesugihan dan Man 3 Cilacap.", Universitas
Islam Negeri Saifuddin Zuhri (Indonesia)

Publication

11	Tay Sui Jian, Muhammad Hafidz Fazli Md Fauadi, Saifudin Hafiz Yahaya, Ahamad Zaki Mohamed Noor, Adi Saptari. "A deep learning approach for automated PCB defect detection: A comprehensive review", Multidisciplinary Reviews, 2024 Publication	<1 %
12	123dok.com Internet Source	<1 %
13	pureadmin.qub.ac.uk Internet Source	<1 %
14	repository.istn.ac.id Internet Source	<1 %
15	jurnal.polibatam.ac.id Internet Source	<1 %
16	digilibadmin.unismuh.ac.id Internet Source	<1 %
17	id.123dok.com Internet Source	<1 %
18	medium.com Internet Source	<1 %
19	pt.scribd.com Internet Source	<1 %
20	pure.rug.nl Internet Source	<1 %
21	Submitted to Universitas Islam Riau Student Paper	<1 %

22	proceedings.mlr.press Internet Source	<1 %
23	www.mdpi.com Internet Source	<1 %
24	repository.unissula.ac.id Internet Source	<1 %
25	Submitted to IUBH - Internationale Hochschule Bad Honnef-Bonn Student Paper	<1 %
26	Submitted to Universitas Jember Student Paper	<1 %
27	Submitted to Universiti Selangor Student Paper	<1 %
28	etheses.uin-malang.ac.id Internet Source	<1 %
29	Submitted to Telkom University Student Paper	<1 %
30	eprints.unram.ac.id Internet Source	<1 %
31	rcf-indonesia.org Internet Source	<1 %
32	arifprt.blogspot.com Internet Source	<1 %
33	arxiv.org Internet Source	<1 %
34	ejurnal.methodist.ac.id Internet Source	<1 %
35	wastedfood.american.edu Internet Source	<1 %

36	www.researchgate.net Internet Source	<1 %
37	Almira Zuhrotus Safira, Sindhu Rakasiwi. "Optimization of Transfer Learning VGG-16 and ResNet50 for Deep Learning-Based Classification of Edible and Poisonous Mushroom Images", Academia Open, 2026 Publication	<1 %
38	Submitted to Universitas Siliwangi Student Paper	<1 %
39	eprints.undip.ac.id Internet Source	<1 %
40	repositori.usu.ac.id Internet Source	<1 %
41	repository.its.ac.id Internet Source	<1 %
42	repository.uin-suska.ac.id Internet Source	<1 %
43	www.jbic.go.jp Internet Source	<1 %
44	Grandhi Sri Kavya, Pamidimarri DattaSai, Soumyasaswati Panigrahi, Preety Kumari Pandey et al. "chapter 7 Electroencephalogram (EEG) AI-Based Analysis of Brain Activity", IGI Global, 2025 Publication	<1 %
45	Ka Chun Fung, Kai-Wen Xue, Cheung-Ming Lai, Kwan-Ho Lin, Kin-Man Lam. "Improving PCB defect detection using selective feature attention and pixel shuffle pyramid", Results in Engineering, 2024	<1 %

Publication

46	aepnurulhidayat.wordpress.com Internet Source	<1 %
47	digilib.itb.ac.id Internet Source	<1 %
48	dspace.uclv.edu.cu Internet Source	<1 %
49	e-journal.hamzanwadi.ac.id Internet Source	<1 %
50	epub.uni-bayreuth.de Internet Source	<1 %
51	open.uct.ac.za Internet Source	<1 %
52	pendidikan.mipa.uns.ac.id Internet Source	<1 %
53	tahtamedia.co.id Internet Source	<1 %
54	repository.upi.edu Internet Source	<1 %

Exclude quotes On

Exclude matches

Off

Exclude bibliography On